

סגמנט סטודיו - פילוח אוטומטי



Segment Studio - היא מערכת אינטראקטיבית לניתוח נתונים שמטרתה לגלות קבוצות נסתרות (Segments) בתוך קובץ CSV באמצעות למידת מכונה. המערכת מאפשרת למשתמש להעלות קובץ נתונים, לבחון כיצד הנתונים מתחלקים לקבוצות בעזרת אלגוריתם **K-Means** ולאחר מכן להשתמש במודל **LLM** כדי להעניק לכל קבוצה שם ותיאור קצר. מטרת הפרויקט היא להדגים תהליך מלא מקצה לקצה:

- טעינת נתונים אמיתיים
- עיבוד מקדים ונירמול
- ניתוח מבנה הקבוצות (Elbow / WCSS)
- חישוב קלאסטרים (K-Means)
- פרשנות בעזרת מודל שפה LLM
- ייצוא התוצאות חזרה לקובץ CSV

המערכת נבנתה כאפליקציית **Streamlit** כדי לאפשר עבודה אינטראקטיבית ונוחה עם הנתונים

שלב 1 – טעינת קובץ CSV והצגתו

בשלב זה המשתמש מעלה קובץ CSV דרך ממשק האפליקציה

המערכת צריכה:

- לטעון את הקובץ ל-Pandas DataFrame של
- להציג את הנתונים בטבלה

שלב זה מאפשר למשתמש להבין עם איזה נתונים הוא עובד

Segment Studio

Choose a CSV file

 Drag and drop file here
Limit 200MB per file • CSV

Browse files



iris_no_label.csv 2.4KB



Step 1: CSV Table

	sepal_length	sepal_width	petal_length	petal_width
26	5	3.4	1.6	0.4
27	5.2	3.5	1.5	0.2
28	5.2	3.4	1.4	0.2
29	4.7	3.2	1.6	0.2
30	4.8	3.1	1.6	0.2
31	5.4	3.4	1.5	0.4
32	5.2	4.1	1.5	0.1
33	5.5	4.2	1.4	0.2
34	4.9	3.1	1.5	0.1
35	5	3.2	1.2	0.2

שלב 2 – חישוב Elbow באמצעות WCSS


המשתמש בוחר טווח של ערכי K (מספר הקלאסטרים):

- K מינימלי
- K מקסימלי

על המערכת:

- להריץ K-Means עבור כל- K בטווח
- לחשב עבור כל- K את מדד WCSS (Within-Cluster Sum of Squares)
- לשמור את התוצאות בטבלה

Step 2: WCSS (Elbow)




	k	WCSS
0	2	223.732
1	3	192.0372
2	4	114.6822
3	5	91.2954
4	6	81.7603
5	7	80.9824
6	8	68.0862
7	9	59.3853
8	10	52.99

לאחר מכן המערכת תצייר גרף Elbow

- ציר X – ערך K
- ציר Y – ערך WCSS

גרף זה מאפשר למשתמש להעריך ויזואלית כמה קלאסטרים מתאימים לנתונים



שלב 3 – יצירת הקלאסטרים

המשתמש בוחר ערך K ולוחץ על כפתור יצירת קלאסטרים

המערכת צריכה:

- להריץ K-Means עם ערך K שנבחר
- להקצות לכל שורה בקובץ מזהה קלאסטר
- לספור כמה תצפיות יש בכל קלאסטר

תוצג טבלה עם העמודות:

- cluster_id
- count
- name, ריק בשלב זה
- Description, ריק בשלב זה

זוהי תוצאת הקיבוץ הגולמית

Step 3: Choose k and create clusters

Select k

7

Create clusters

Cluster counts (name/description empty for now)

	cluster_id	count	name	description
0	0	17		
1	1	27		
2	2	23		
3	3	2		
4	4	25		
5	5	19		
6	6	37		

שלב 4 – מתן משמעות לקלאסטרים בעזרת LLM

לכל קלאסטר המערכת יוצרת סיכום הכולל:

- מספר התצפיות בקבוצה 📊
- ממוצע הפיצ'רים המספריים 📉
- הערכים הקטגוריאליים השכיחים ביותר 🏷️

הסיכום נשלח למודל LLM 🤖 והמודל מתבקש להחזיר:

- שם קצר לקבוצה
- תיאור בן שורה אחת

המערכת תציג טבלה חדשה עם:

- cluster_id
- count
- name
- description

כך הקלאסטרים הופכים למקטעים מובנים ואנושיים

Step 4: Generate group name + description (LLaMA)

Generate names/descriptions with LLaMA

Cluster labels (with name + description)

	cluster_id	count	name	description
0	0	17	Iris Flower Clusters	A classification of iris flowers based on their physical characteristics.
1	1	27	Iridescent Bloomers	A cluster of flowers with varying colors and shapes.
2	2	23	Iris Data Analysis	An analysis of the Iris flower dataset.
3	3	2	Petal Characteristics	A group of flowers with distinct petal features.
4	4	25	Iris Variations	A group of iris flower species with distinct characteristics.
5	5	19	Iris Dataset Subset	This cluster represents a subset of iris flower data.
6	6	37	Iris Species	A group of flowers with unique characteristics.

Step 5: Export clustered CSV

Download clustered CSV

ייצוא חזרה ל-CSV

בשלב האחרון נוצרת גרסה חדשה של קובץ הנתונים

CSV → ⚙️ → Clusters → 🗨️ → Named Groups → 📄 CSV

המערכת:

- לוקחת את קובץ ה-CSV המקורי
- מוסיפה עמודה חדשה בשם cluster_name
- לכל שורה משויכת שם הקבוצה אליה היא שייכת

הקובץ יישמר בשם `<original_name>_clustered.csv`

★ בנוסים (רשות)

- החלף את WCSS במדד **Silhouette Score**
- בשלב בחירת ה-K הוסף כפתור – **בחירת k אוטומטית**, אם השתמשת במדד *Silhouette Score* אז בחר את הערך הגבוה ביותר, עבור מדד WCSS - שאל את ה LLM מי הכי טוב
- ניקוי חריגים. אתר נקודות שהמרחק שלהם מהמרכז חריג והסר אותם

הנחיות להגשה

- יש לעלות את קבצי הקוד ואת קובץ המודל ל- GITHUB

📧 מייל להגשה:

pythonai211225+project2studio@gmail.com